

BIG DATA CON DATOS ABIERTOS REALES

Desarrollar un proyecto completo de Big Data utilizando exclusivamente datos abiertos oficiales y reales del INEI, ENDES o de otra plataforma gubernamental confiable, aplicando técnicas de bases de datos, normalización, ETL, análisis de patrones y modelos predictivos.

El estudiante deberá ingresar a una plataforma de datos abiertos oficiales y seleccionar un conjunto de datos con millones de registros relacionado con salud, educación, pobreza, nutrición, población, transporte o medio ambiente.

Plataformas permitidas:

- INEI: <https://www.inei.gob.pe>
- Datos Abiertos Perú: <https://www.datosabiertos.gob.pe>
- Banco Mundial: <https://datos.bancomundial.org>

Debe presentarse:

- Plataforma utilizada.
- Nombre del dataset seleccionado.
- Año o período de los datos.
- Número aproximado de registros.

Descripción del conjunto de datos

Analizar el archivo descargado y describirá sus características principales.

- Total de registros.
- Total de variables o columnas.
- Tipo de dato de cada variable (numérico, texto, fecha o booleano).
- Variables más relevantes para el análisis.
- Problema social o público que puede estudiarse con la información.

Diseño de la base de datos

Construir un modelo entidad–relación a partir del conjunto de datos seleccionado.

- Identificación de entidades.
- Identificación de atributos.
- Definición de relaciones.
- Elaboración del diagrama entidad–relación.

Además, deberá explicar:

- Qué tabla será considerada principal.
- Qué tablas serán auxiliares.
- Cómo se relacionarán entre sí.
- Normalización de la base de datos

Aplicar el proceso de normalización hasta la Tercera Forma Normal (3FN).

- Primera Forma Normal (1FN).
- Segunda Forma Normal (2FN).
- Tercera Forma Normal (3FN).

Asimismo, deberá justificar:

- Qué datos repetidos fueron eliminados.
- Qué dependencias funcionales fueron corregidas.
- Cómo la normalización mejora la integridad y consistencia de la información.

Implementación en SQL Server o PostgreSQL

Implementar físicamente la base de datos en un gestor relacional.

Deberá entregar los scripts SQL de:

- Creación de la base de datos.
- Creación de tablas.
- Definición de claves primarias.
- Definición de claves foráneas.

- Inserción de una muestra representativa de datos.

Además, deberá crearse:

- Un mínimo de tres índices.
- Un mínimo de dos vistas analíticas.
- Un procedimiento almacenado.

Proceso ETL y limpieza de datos

Ejecutar un proceso ETL utilizando Python, SQL o Apache Spark.

- Extracción de los datos originales.
- Eliminación de registros duplicados.
- Tratamiento de valores nulos.
- Conversión de tipos de datos.
- Carga de la información en la base de datos final.

Deberá presentarse:

- Código utilizado.
- Capturas del proceso.
- Explicación de las transformaciones realizadas.

Análisis de patrones y secuencias temporales

El estudiante analizará el comportamiento histórico de los datos y buscará patrones relevantes.

Deberá generar:

- Tablas resumen - Gráficos de líneas - Gráficos de barras.
- Tendencias por año.
- Comparaciones por región, departamento o grupo poblacional.

Deberá responder preguntas como:

- ¿Qué regiones presentan los valores más altos?
- ¿Cómo ha variado el indicador a lo largo del tiempo?
- ¿Existen patrones repetitivos o tendencias temporales?

Modelo predictivo y proyección futura

Construir un modelo predictivo mediante regresión lineal u otro algoritmo de aprendizaje automático.

Deberá incluir:

- Variable independiente (X) - Variable dependiente (Y).
- Ecuación del modelo.
- Código del modelo en Python o herramienta utilizada.
- Gráfico de regresión.
- Predicción para los próximos tres a cinco años.

Asimismo, deberá interpretar:

- El significado de los coeficientes.
- Si la tendencia es creciente o decreciente.
- Qué podría ocurrir en el futuro según los datos históricos analizados.

Elaboración del informe final

Entregar un informe técnico en formato PDF que incluya la siguiente estructura:

- Portada.
- Introducción.
- Objetivos.
- Fuente oficial de los datos.
- Descripción del dataset.
- Modelo entidad–relación.
- Proceso de normalización.
- Scripts SQL.
- Proceso ETL.
- Análisis de patrones.
- Modelo predictivo.
- Gráficos y visualizaciones.
- Interpretación de resultados.
- Conclusiones.